



ITSRLL
INSTITUTO TECNOLÓGICO SUPERIOR
DE LA REGIÓN DE LOS LLANOS

Ingeniería Mecatrónica

PROGRAMACIÓN AVANZADA

Enero – Junio 2025
M.C. Osbaldo Aragón Banderas

UNIDAD:

1	2	3	4	5
---	---	---	---	---

Actividad número:

Nombre de actividad:

PROGRAMA. Implementación de Perceptrón

Actividad realizada por:

Martin Eduardo Montiel Salazar No. Control: 21030018

Guadalupe Victoria, Durango

Fecha de entrega:

18	02	2025
----	----	------

INTRODUCCIÓN

El presente reporte se enfoca en la implementación y análisis de un modelo de perceptrón para la clasificación de solicitudes de préstamo. En el contexto actual, donde la automatización y la toma de decisiones basadas en datos se han vuelto fundamentales en el sector financiero, contar con herramientas que permitan evaluar de manera rápida y eficiente la viabilidad crediticia es esencial. Este trabajo utiliza un perceptrón, uno de los modelos más simples de redes neuronales, para distinguir entre solicitudes aprobadas y rechazadas basándose en variables financieras clave, tales como el puntaje de crédito, los ingresos mensuales, el monto del préstamo solicitado y la relación deuda/ingresos.

Para optimizar el desempeño del modelo, se aplicó una técnica de normalización Min-Max a los datos de entrada, lo que permitió homogeneizar las escalas de las diferentes características. Esta etapa de preprocesamiento es crítica, ya que facilita el ajuste de los pesos y contribuye a una convergencia más estable durante el entrenamiento. El proceso se llevó a cabo a lo largo de múltiples épocas, durante las cuales se realizó un seguimiento detallado de la evolución de los errores, así como de los ajustes graduales en los pesos y el sesgo.

El análisis comparativo de los resultados obtenidos ha permitido identificar las fortalezas del enfoque utilizado y detectar áreas de mejora, especialmente en lo que respecta a la estabilidad del proceso de aprendizaje y la precisión en la clasificación.

OBJETIVO

Implementar y entrenar un perceptrón en Python que permita clasificar solicitudes de préstamo en aprobadas (1) o rechazadas (0), en función de variables financieras relevantes. Se busca reforzar el conocimiento en aprendizaje supervisado, el ajuste de pesos en redes neuronales simples y la implementación de modelos de clasificación binaria.

NOTEBOOK

```
import numpy as np

x = np.array([
    [750, 5.0, 20.0, 0.3],
    [600, 3.0, 15.0, 0.6],
    [680, 4.0, 10.0, 0.4],
    [550, 2.5, 8.0, 0.7],
    [800, 6.0, 25.0, 0.2]])

y = np.array([1, 0, 1, 0, 1])
#1= Aprobada 0=Rechazada

#Normalizacion de dastos de entrada
def normalize(values, min_vals, max_vals):
    return [(v - min_v) / (max_v - min_v) for v, min_v, max_v in zip(values, min_vals, max_vals)]

min_vals = [500, 2.5, 30, 0.2] # Valores mínimos de cada característica
max_vals = [800, 6.0, 100, 0.7] # Valores máximos de cada característica
```

```
min_vals = [500, 2.5, 30, 0.2] # Valores mínimos de cada característica
max_vals = [800, 6.0, 100, 0.7] # Valores máximos de cada característica

x = np.array([normalize(row, min_vals, max_vals) for row in x])

#Parametros del perceptron
learning_rate = 0.1
epoch=20

weights = np.random.rand(4)
bias = np.random.rand()

def activacion_function(x):
    return 1 if x >= 0 else 0
```

```
#Entrenamiento del perceptron
for epoch in range(epoch):
    print(f" Época {epoch + 1}:")
    for i in range(len(x)):
        linear_output = np.dot(x[i], weights) + bias
        prediccion = activacion_function(linear_output)
        error = y[i] - prediccion
        weights += learning_rate * error * x[i]
        bias += learning_rate * error
        print(f"Muestra {i+1}: Entrada {x[i]}, Esperado {y[i]}, Predicción {prediccion}, Error {error}")
    print(f"Pesos actualizados: {weights}, Bias actualizado: {bias}\n")
```

```
print("Ingrese los datos de la nueva solicitud de préstamo:")
puntaje_credito = float(input("Puntaje de crédito (300-850): "))
ingresos = float(input("Ingresos mensuales (en miles de pesos): "))
monto_prestamo = float(input("Monto del préstamo solicitado (en miles de pesos): "))
relacion_deuda_ingresos = float(input("Relación deuda/ingresos (ej. 0.2, 0.5): "))

nueva_solicitud = np.array([puntaje_credito, ingresos, monto_prestamo, relacion_deuda_ingresos])
nueva_solicitud_normalizada = (nueva_solicitud - x_min) / (x_max - x_min)

resultado = activacion_function(np.dot(nueva_solicitud_normalizada, weights) + bias)
print(f"Resultado de la nueva solicitud: {'Aprobada :}' if resultado == 1 else 'Rechazada :('}")
```

RESULTADOS

Época 1:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 1, Error -1
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 1, Error 0
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 1, Error -1
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.34801276 0.10760832 0.47340674 0.46332033], Bias actualizado: -0.17547272162755184

Época 2:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 1, Error -1
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 0, Error 1
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 1, Error -1
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.35801276 0.13617975 0.49769246 0.32332033], Bias actualizado: -0.2754727216275519

Época 3:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 1, Error -1
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 0, Error 1
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 0, Error 0
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.38467943 0.16475118 0.4905496 0.28332033], Bias actualizado: -0.2754727216275519

Época 4:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 0, Error 0
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 0, Error 1
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 1, Error -1
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.42801276 0.20760832 0.49340674 0.22332033], Bias actualizado: -0.2754727216275519

Época 5:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 0, Error 0
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 1, Error 0
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 0, Error 0
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.42801276 0.20760832 0.49340674 0.22332033], Bias actualizado: -0.2754727216275519

Época 6:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 0, Error 0
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 1, Error 0
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 0, Error 0
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.42801276 0.20760832 0.49340674 0.22332033], Bias actualizado: -0.2754727216275519

Época 13:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 0, Error 0
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 1, Error 0
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 0, Error 0
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.42801276 0.20760832 0.49340674 0.22332033], Bias actualizado: -0.2754727216275519

Época 14:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 0, Error 0
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 1, Error 0
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 0, Error 0
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.42801276 0.20760832 0.49340674 0.22332033], Bias actualizado: -0.2754727216275519

Época 15:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 0, Error 0
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 1, Error 0
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 0, Error 0
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.42801276 0.20760832 0.49340674 0.22332033], Bias actualizado: -0.2754727216275519

Época 16:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 0, Error 0
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 1, Error 0
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 0, Error 0
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.42801276 0.20760832 0.49340674 0.22332033], Bias actualizado: -0.2754727216275519

Época 17:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 0, Error 0
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 1, Error 0
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 0, Error 0
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.42801276 0.20760832 0.49340674 0.22332033], Bias actualizado: -0.2754727216275519

Época 18:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 0, Error 0
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 1, Error 0
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 0, Error 0
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.42801276 0.20760832 0.49340674 0.22332033], Bias actualizado: -0.2754727216275519

Época 20:

Muestra 1: Entrada [0.83333333 0.71428571 -0.14285714 0.2], Esperado 1, Predicción 1, Error 0
Muestra 2: Entrada [0.33333333 0.14285714 -0.21428571 0.8], Esperado 0, Predicción 0, Error 0
Muestra 3: Entrada [0.6 0.42857143 -0.28571429 0.4], Esperado 1, Predicción 1, Error 0
Muestra 4: Entrada [0.16666667 0. -0.31428571 1.], Esperado 0, Predicción 0, Error 0
Muestra 5: Entrada [1. 1. -0.07142857 0.], Esperado 1, Predicción 1, Error 0
Pesos actualizados: [0.42801276 0.20760832 0.49340674 0.22332033], Bias actualizado: -0.2754727216275519

Ingrese los datos de la nueva solicitud de préstamo:

Puntaje de crédito (300-850): 300

Ingresos mensuales (en miles de pesos): 25

Monto del préstamo solicitado (en miles de pesos): 5

Relación deuda/ingresos (ej. 0.2, 0.5): 0.2

Resultado de la nueva solicitud: Aprobada :)

ANÁLISIS DE RESULTADOS

1. Evolución de los errores en las épocas iniciales

Durante las primeras épocas se observa que el perceptrón comete ciertos errores en algunas muestras, en particular en la muestra 2 y la muestra 4. Esto significa que, al inicio, el modelo clasifica de forma incorrecta esos ejemplos: por ejemplo, se esperaba un 0 pero el perceptrón predijo un 1, o viceversa. Estos errores son naturales en un proceso de entrenamiento, ya que el algoritmo aún está "aprendiendo" la relación entre las características de entrada y las etiquetas de salida. Los errores iniciales indican que el modelo detecta discrepancias y comienza a ajustar sus parámetros (pesos y bias) para corregirlos. Es en este punto cuando se evidencia el proceso de aprendizaje, ya que el algoritmo utiliza el error para actualizar sus valores y acercarse a una solución correcta.

2. Ajuste y evolución de los pesos y el bias

En este punto se aprecia que los ajustes de los pesos y del bias se realizan de forma gradual. Al inicio, los pesos parten de unos valores aleatorios y, con cada muestra y cada época, se van actualizando en función del error cometido. En el Conjunto 2, se puede notar que los cambios en los parámetros son moderados: por ejemplo, los pesos y el bias van tomando valores nuevos en cada época, pero sin cambios bruscos. A medida que se avanza en el entrenamiento, estos ajustes llevan a que el modelo se acerque a una solución estable. Desde la época 6 en adelante, los pesos y el bias se estabilizan, lo que significa que el modelo ha encontrado una configuración en la que las predicciones son correctas para todas las muestras del conjunto de entrenamiento. Esto es un indicador claro de que el proceso de aprendizaje ha convergido y que el modelo ha "aprendido" adecuadamente la relación entre las entradas y las salidas.

3. Precisión de la clasificación

Una vez que el modelo ha alcanzado la época 6, se observa que todas las muestras se clasifican correctamente, es decir, la salida del perceptrón coincide con las etiquetas esperadas en cada caso. Esto se traduce en que no se reportan errores

en las épocas posteriores, desde la 6 hasta la 20. La precisión de la clasificación es, por tanto, excelente en este punto, lo que indica que el perceptrón ha logrado separar de forma correcta las clases (en este caso, solicitudes aprobadas y rechazadas). El hecho de que el modelo mantenga esta precisión a lo largo de varias épocas sin necesidad de ajustar más los parámetros es una señal de que la solución encontrada es robusta y estable. Además, demuestra que, al haber normalizado los datos y elegir una tasa de aprendizaje adecuada, el perceptrón es capaz de aprender la relación subyacente en el conjunto de datos, incluso siendo un modelo lineal, lo que implica que los datos eran linealmente separables tras la normalización.